Programming Assignment 3: Bag-of-Visual-Words Image Recognition

202511013 권세현

https://github.com/tpgusrnjs/CSE404/tree/main/pa3

1 Introduction

Bag-of-Visual-Words는 이미지의 국소 패치를 시각적 단어로 변환해 지역 특징들의 집합으로 나타내는 방법이다. Dense SIFT로 특징을 추출한 뒤 K-means 클러스터를 통해 codebook을 생성하며, 이미지를 단어의 빈도가 담긴 히스토그램 벡터로 인코딩하여 SVM 분류기로 학습을 수행한다.

그러나 BoVW는 특징의 공간적 위치 정보를 고려하지 못한다는 한계가 있다. 이를 보완하기 위해 이미지를 여러 단계로 나누어 공간 정보를 반영하는 Spatial Pyramid Matching 기법이 사용된다. 본 프로젝트에서는 CALTECH-20 데이터셋을 활용해 BoVW 기반 분류를 수행하고, confusion matrix를 통해 기본 모델과 SPM의 성능 차이를 비교 분석한다.

2 Method

2.1 T1: Dense SIFT extraction

Dense SIFT는 이미지 전 영역을 일정 간격의 격자로 샘플링하여 특징을 계산하는 방법이다. 각 위치마다 128차원의 특징 벡터를 추출한다. 이를 통해 이미지의 구조 정보를 촘촘하게 반영한다.

2.2 T2: Codebook construction

K-Means Clustering을 이용한 Visual Vocabulary 구성은 모든 학습 이미지에서 추출된 Dense SIFT descriptor를 모은 뒤 이를 K개의 클러스터로 군집화하여 codebook을 정의한다. 이때 목적 함수는

$$\min_{\{\mu_k\}} \sum_{k=1}^{K} \sum_{d_i \in C_k} \|d_i - \mu_k\|^2$$

이다. 여기서 d_i는 descriptor, μ_k는 k번째 클러스터 중심, C_k는 해당 클러스터 descriptors의 집합을 의미한다. 100K 규모로 descriptors를 샘플링하고 MiniBatch K-Means를 사용해 계산 효율을 높였다.

2.3 T3: BoVW histogram encoding

추출된 local descriptors를 학습된 codebook 시각적 단어에 할당한 뒤, 단어의 등장 빈도를 기반으로 특징 벡터로 표현하는 방법이다. descriptor d_i는 가까운 코드워드 μ_k에 할당되며, 각 차원은:

$$h_k = \sum_{i=1}^{N} 1\left[k = \arg\min_j \|d_i - \mu_j\|\right]$$

이다. h_k는 k번째 시각적 단어의 등장 횟수를 의미한다. 이미지 크기 같은 편향을 제거하기 위해 $\ell 1$ 정규화를 적용했다. 이를 통해 K차원의 특징 벡터로 변환되어 분류기 입력으로 활용된다.

2.4 T4: Kernel comparison

Linear SVM은 최적의 선형 결정 경계를 찾는 분류기이다. χ^2 kernel SVM은 χ^2 distance를 기반으로 유사도를 계산하고 kernel 함수로 변환하여 비선형 분류를 수행하는 방법이다.

$$\chi^2(h, h') = \sum_{k=1}^{K} \frac{(h_k - h'_k)^2}{h_k + h'_k + \varepsilon}, \quad K_{\chi^2}(h, h') = \exp\left(-\gamma \chi^2(h, h')\right)$$

2.5 T5: Spatial Pyramid Matching

BoVW는 visual word의 등장 빈도만을 사용해 공간 정보가 없다. Spatial Pyramid Matching은 격자로 분할하여 각 영역에서 별도의 BoVW 히스토그램을 계산한다. 각 레벨에서 생성된 히스토그램은 가중치를 적용한 후 연결되며, 최종적으로 $\ell 2$ 정규화를 통해 하나의 특징 벡터로 사용된다.

$$f_{\text{SPM}} = \left[w_0 h^{(0)},\ w_1 h^{(1)},\ w_2 h^{(2)}\right] \left(w_0 = \frac{1}{4}, w_1 = \frac{1}{4}, w_2 = \frac{1}{2}\right)$$

2.6 T6: Result & Analysis

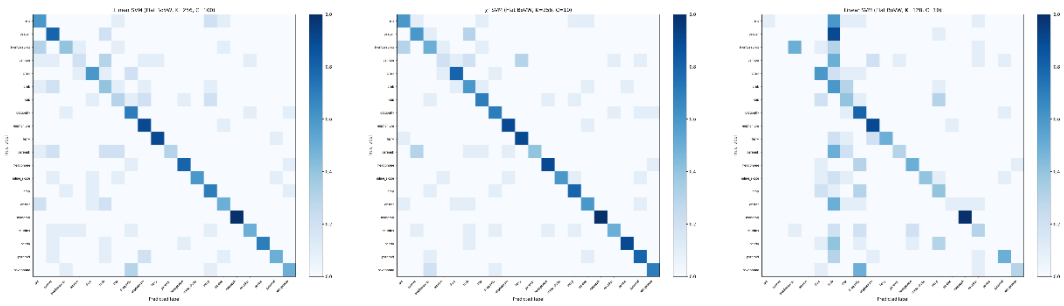

Figure 1 20×20 confusion matrix of best model (lowest resource), linear svm with flat bovw K=256 & C=100(left), χ^2 svm with flat bovw with K=256 & C=100(middle), χ^2 svm with spm bovw with K=256 & C=100(right)

K	C	Flat BoVW		SPM
		linear svm	χ^2 svm	
64	100	52.50	56.50	66.00
128		58.50	59.00	**70.00**
256		59.50	68.50	**70.00**

Table 1 Accuracy table when C=100

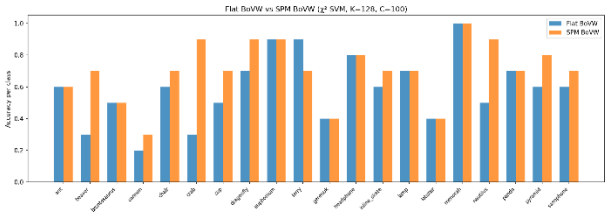

Figure 2 Accuracy per class Flat BoVW vs SPM (K=128, C=100)

Figure 3에서 beaver, cannon, crab, cup, dragonfly, nautilus, pyramid, saxophone과 같은 class에서 SPM의 정확도가 확연히 높아지는 것을 확인할 수 있다. 이는 class별 이미지의 특성에서 기인한 것이라 볼 수 있는데, 기하학적으로 일정한 구조를 가지거나, 유사한 질감을 가진 다른 객체의 공간적 배치를 학습한 것이다. 특히 crab의 정확도가 오른 것은 유사한 질감을 가진 beaver로 분류되던 것이 방사형 대칭성인 게의 신체구조를 학습하여, 중앙 몸통, 주변부 다리 등의 특징을 파악하였기 때문이다.

3 Discussion

Flat BoVW 환경에서는 Linear SVM보다 χ^2 kernel SVM이 전반적으로 높은 정확도를 보였다. 이는 BoVW 특징이 histogram 기반 표현이기 때문에 선형 분리보다 histogram 간 상대적 차이를 반영하는 χ^2 distance가 적합하기 때문이다. 또한 vocabulary size K가 증가할수록 성능이 향상되는 경향을 보였다. 그러나 SPM에서는 K=128과 K=256에서 동일하게 70.00%의 정확도를 보였는데 이는 Flat BoVW은 시각 단어의 풍부함에 의존하지만 SPM은 공간적 레이아웃 정보를 통해 이미 충분한 변별력을 확보하였기에 K=128에서 성능이 포화됨을 의미한다. confusion matrix를 통해서 SPM이 중심과 주변부 구조가 뚜렷한 객체에서 성능 향상을 관찰할 수 있었으며 이는 객체 분류에서 spatial information의 중요성이 클래스 특성에 따라 다르게 작용함을 시사한다

한편 Dense SIFT와 BoVW는 handcrafted feature 기반 접근법이기 때문에 semantic-level representation을 충분히 학습하기 어렵다. 또한 K-Means 기반 codebook은 descriptor distribution에 민감하며, vocabulary 생성 과정에서 정보 손실이 발생할 수 있다.

4 Conclusion

본 프로젝트에서는 Dense SIFT, K-Means 기반 visual vocabulary, BoVW histogram encoding, χ^2 kernel SVM, Spatial Pyramid Matching을 이용한 이미지 분류 파이프라인을 구현하였다. feature extraction, vector quantization, histogram representation, kernel-based classification 등 전통적인 컴퓨터 비전 기법의 핵심 개념을 이해할 수 있었다. 비록 최근 딥러닝이 더 높은 성능을 보이고 있지만, BoVW와 SPM은 현대 vision model의 기반이 되는 중요한 아이디어를 제공한다는 점에서 의미가 있다.